

Zillow Offers

Introduction au Machine Learning - Etude de cas


Theo Lopes Quintas

BPCE Payment Services,
Université Paris Dauphine


2026

Contexte

L'entreprise Zillow est un des leader américain de l'immobilier en ligne. En 2019 une nouvelle ligne business **Zillow Offers** : acheter, rénover et revendre avec profit des maisons. Pour le faire, ils utilisent le modèle nommé *Zestimate* pour évaluer le prix de la maison à l'achat et à la vente.



(a) Prix moyen de vente d'une maison aux États-Unis.
En bleu la période d'entraînement de Zestimate.



(b) Nombre d'achat et de vente de maison par Zillow Group


En novembre 2021, l'entreprise coupe le service après avoir acheté plus de 9000 maisons mais n'avoir réussi à en revendre que 3000 : la perte enregistré est de 569 M\$.

En résumé


1	Contexte	1
2	Dataset shifts	3
3	Annexes	7

Les différents shifts


On dit qu'un **dataset shift** a lieu quand les distributions du dataset d'entraînement et du dataset de test sont différentes. On note trois types de *shifts* :



(a) Covariate shift : la distribution de X change



(b) Label shift : la distribution de y change



(c) Concept drift : la relation entre X et y change (**entraînement** et **test**)

Figure – Différents dataset shifts

Zestimate a vécu les trois, et un quatrième facteur a amplifié ces phénomènes : le nombre de transaction s'est fortement réduit, empêchant le modèle d'estimer les changements ayant lieu.

Dataset shifts

PSI : Population Stability Index

Pour détecter le **Covariate shift** (les changements dans les features), une possibilité est de calculer le *Population Stability Index*. Si on note X^{train} la distribution d'une feature X dans le dataset d'entraînement et X^{test} dans le dataset de test. Alors on définit :

$$\text{PSI}(X^{\text{train}}, X^{\text{test}}) = \sum_i (X_i^{\text{train}} - X_i^{\text{test}}) \ln \left(\frac{X_i^{\text{train}}}{X_i^{\text{test}}} \right)$$

L'intérêt de cette métrique est que son interprétation est partagée dans plusieurs domaines des risques :

- ▶ $\text{PSI} < 0.1$: peu de changement
- ▶ $0.1 \leq \text{PSI} < 0.2$: changement léger
- ▶ $\text{PSI} \geq 0.2$: changement important qui nécessite une investigation

Si notre cible Y est labellisable *rapidement*, alors le PSI peut également détecter le **Label shift**.

En résumé

1	Contexte	1
2	Dataset shifts	3
2.1	Comment les détecter ?	4
3	Annexes	7

Annexes

Divergence de Kullback-Leibler

Pour deux mesures de probabilité P et Q on définit :

$$\text{KL}(P\|Q) = \mathbb{E}_{y \sim P} \left[\log \left(\frac{P(y)}{Q(y)} \right) \right] \quad (\text{Kullback-Leibler})$$

Cette quantité est la **divergence de Kullback-Leibler** qui est strictement positive ou nulle quand $P = Q$ presque partout. Elle mesure le **changement de distribution** entre P et Q , plus précisément l'erreur que l'on fait en approchant la véritable distribution P par la distribution Q .

Annexes

Divergence de Kullback-Leibler




Figure – Kullback-Leibler divergence entre deux gaussienne