

Amazon CV

Introduction au Machine Learning - Etude de cas

Theo Lopes Quintas

BPCE Payment Services,
Université Paris Dauphine

2026

Contexte

Une IA chargée du recrutement pour répondre à la croissance d'Amazon

Fondée en 1994, Amazon a connu récemment des défis dans le domaine RH. En 2014, l'entreprise compte plus de 150 000 employés avec une durée médiane de *carrière* d'une année. On suppose qu'il faut faire 5 entretiens pour trouver un bon candidat.

- Pour **maintenir** le nombre de personne, il fallait faire 375 000 entretiens
- Pour atteindre les objectifs de **développement**, il a fallu faire 775 000 entretiens en 2014 pour 2015




Figure – Nombre d'employés chez Amazon

Comment répondre à ce challenge avec du Machine Learning ?

Contexte

Problème de biais sexiste

- 2014 - Amazon lance un modèle dont l'objectif est d'identifier les meilleurs CV pour réduire le nombre de CV traités par les ressources humaines
- 2015 - L'équipe découvre que le modèle ne traite pas équitablement les hommes et les femmes, notamment sur des profils *techniques*
- 2018 - Des sources anonymes de l'équipe ayant réalisé l'algorithme révèlent à Reuters que l'algorithme rejette systématiquement les CV féminin

Amazon affirme que le modèle, entraîné sur les recrutements des dix dernières années, n'a été utilisé qu'à des fins d'aide à la décision et qu'il a été revu pour ne plus produire ce biais.

Mais, que s'est-il passé ?

En résumé

1	Contexte	1
2	Identifier des biais	4
3	Mitiger des biais	8

Identifier des biais

Analyses de performances par sous-groupes

Une première manière de *connaître* son modèle est de mesurer la performance, avec plusieurs métriques adaptées, selon **plusieurs sous-groupes**.




Figure – F1-Score évalué pour plusieurs sous-groupe

La méthode ne fonctionne que si la cible y est **non biaisé**!

Identifier des biais

Adversarial debiasing

Avec un modèle entraîné, si dès le départ nous avons un attribut **protégé** qui ne fait pas partie des features, nous pouvons vérifier que l'on ne peut pas le *retrouver*.

Adversarial debiasing

1. Entraîner un modèle sur la cible y
2. Entraîner un nouveau modèle, à partir des prédictions du premier modèle, avec comme cible un attribut protégé
3. Etudier les résultats




Figure – Exemple de distribution d'un score

Si le modèle **réussi**, alors on peut chercher à comprendre à partir de quelle features il a pu reconstruire l'attribut protégé.

Identifier des biais

Adversarial debiasing - Cas spécifique du traitement du langage

Particulièrement dans le cadre du traitement du langage, la multicolinéarité des méthodes traditionnelles peut entraîner une reconstruction partielle d'attribut protégé [Dayanik and Padó, 2021].

Particulièrement en français, le genre peut rapidement être identifié :

1. Genau hier wurde ich geboren und verbrachte die ersten sieben Jahre meines Lebens
2. Esta es la tierra en la que naci y pase los primeros siete anos de mi vida
3. Je suis **née** ici même, et j'y ai passé les sept premières années de ma vie

En résumé

1	Contexte	1
2	Identifier des biais	4
2.1	Analyses de performances par sous-groupes	4
2.2	Adversarial debiasing	5
3	Mitiger des biais	8

Mitiger des biais

Avant l'entraînement

On peut essayer de mitiger les biais avant l'entraînement en traitant directement les données.

- ▶ **Allouer** plus de poids à un groupe donné dans les cas positifs : soit dans la fonction de perte soit par ré-échantillonnage.
- ▶ **Modifier** les labels : avec des données synthétiques ou des cas réels modifiés
- ▶ **Supprimer** les features *problématiques* : autrement dit *fairness through unawareness*¹


Les deux premières options modifient les distributions observées en pratiques et peuvent conduire à des résultats éloignés de ceux qui seront observés. Le dernier ne donne aucune garantie : les données sont multidimensionnelles et relativement corrélées. Il n'est donc pas impossible qu'on puisse déduire qu'un CV est celui d'une femme sans avoir la mention explicite.

1. C'est l'approche choisie par Amazon.


Mitiger des biais

Après l'entraînement

On peut également entraîner un modèle tel quel, et choisir de modifier la manière dont on l'utilise. Précisément en choisissant des seuils spécifiques plutôt qu'un seuil unique. [Hardt et al., 2016] traite spécifiquement ce sujet et démontre que cette solution est optimale, en supposant que les labels sont *justes*.



(a) La méthode fonctionne



(b) La méthode n'est pas utile

Figure – Distributions de deux modèles pour les candidatures d'hommes et de femmes acceptés (en trait pleins) et rejetés (en pointillés)

En résumé

1	Contexte	1
2	Identifier des biais	4
3	Mitiger des biais	8
3.1	Avant l'entraînement	8
3.2	Après l'entraînement	9

Bibliographie I



Dayanik, E. and Padó, S. (2021).

Disentangling document topic and author gender in multiple languages : Lessons for adversarial debiasing.

In Proceedings of the Eleventh Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis.



Hardt, M., Price, E., and Srebro, N. (2016).

Equality of opportunity in supervised learning.

Advances in neural information processing systems.