

Motivation et formalisation

Introduction au Machine Learning

Theo Lopes Quintas

BPCE Payment Services,
Université Paris Dauphine

2026

Motivation

Trois orientations

Nous ne pouvons qu'avoir un aperçu du futur, mais cela suffit pour comprendre qu'il y a beaucoup à faire.

— Alan Turing (1950)




Je dirais que l'on n'apprend que dans les cours où l'on travaille sur des problèmes. Il est essentiel que les étudiants tentent de résoudre des problèmes. [...] Se borner à écouter ne sert pas à grand chose.

— Werner Heisenberg (1963)



La logique ne fait que sanctionner les conquêtes de l'intuition.

— Jacques Hadamard (1972)



Les différentes approches du Machine Learning

Supervisé ou non-supervisé

Nous travaillerons dans ce cours sur deux approches possible en Machine Learning : l'apprentissage **supervisé** et l'apprentissage **non-supervisé**.




Figure – Deux types d'apprentissage schématisé

Les deux cas nécessite des **données** et le supervisé a besoin également d'une **cible**. C'est sur ce dernier que porte la première partie du cours.

Apprentissage supervisé

Dataset

Le Machine Learning supervisé nécessite des **informations** (notées X ou x) pour prédire une **cible** (notée Y ou y).

$$\mathcal{D} = \left\{ (x^{(i)}, y_i) \mid \forall i \leq \underbrace{n}_{\text{Nombre d'observations}}, x^{(i)} \in \underbrace{\mathbb{R}^d}_{\text{Nombre d'informations}}, y_i \in \mathcal{Y} \right\} \quad (1)$$


L'hypothèse du datascientist est qu'il existe une certaine fonction f , inconnue a priori, qui fait le lien entre les observations $x \in \mathbb{R}^d$ et la réponse y .

$$\exists f: \mathbb{R}^d \rightarrow \mathcal{Y}, \forall i \leq n, y_i = f(x^{(i)}) + \varepsilon_i \text{ avec } \varepsilon_i \text{ le bruit}$$

Apprentissage supervisé

Fonction de perte et fonction de coût

Exercice 1



Trouver la meilleure fonction f_θ qui renvoie 0 pour les ronds bleus et 1 pour les ronds rouges parmi les propositions suivantes avec

$$\mathcal{L}(\theta; x, y) = \mathbb{1}_{y \neq f_\theta(x_1, x_2)} \text{ donc } \mathcal{C}(\theta; X, y) = \sum_{i=1}^n \mathcal{L}(\theta, x, y).$$

1. $f_\theta(x_1, x_2) = \mathbb{1}_{x_1 \leq \theta}$
2. $f_\theta(x_1, x_2) = \mathbb{1}_{x_2 \leq \theta}$

A partir du dataset et de notre hypothèse, on définit deux fonctions :


- La **fonction de perte**
 $\mathcal{L} : \mathbb{R}^{d'} \times \mathbb{R}^d \times \mathbb{R}$
- La **fonction de coût**
 $\mathcal{C} : \mathbb{R}^{d'} \times \mathcal{M}_{n,d} \times \mathbb{R}^n$

La majorité du temps la fonction de coût correspond à la somme des fonctions de perte pour chaque observation.

Sélection de modèle

Train, Validation, Test

A partir du dataset d'entraînement on peut former un jeu de **Train** et un de **Validation**. Le premier sert à apprendre les paramètres des différents modèles que l'on souhaite tester, le second sert à mesurer la performance pour trouver le *meilleur*. Puis on peut exploiter le modèle gagnant sur le jeu de **Test**.



Sélection de modèle

Validation croisée

Plutôt que d'avoir une unique valeur de performance, on peut en obtenir plusieurs en réalisant une **validation croisée**. Il faut garder en tête que puisque le dataset est découpé en plusieurs pli aléatoirement, **il ne doit pas être dépendant du temps**.



Figure – Schéma d'une validation croisée